

Perfiles de pacientes diabéticos para un estudio de seguimiento post-alta

Laboratorio de semana 8 (GMM, KDE y DBSCAN) adaptado al dataset *Diabetes 130-US hospitals, 1999–2008* · Análisis a nivel paciente con todo su historial de ingresos · Notebook: [semana08_pacientes_agregados.ipynb](#)

1. Objetivo de negocio

Las readmisiones hospitalarias en menos de 30 días son costosas para los hospitales y en EE. UU. se penalizan. La gerencia quiere **focalizar un programa de seguimiento después del alta** (llamadas, citas tempranas, revisión de medicación) en los pacientes que más lo necesitan, sin dispersar recursos limitados. La pregunta analítica, adaptada de la guía de semana 8 (donde un comité buscaba zonas de un mapa), es: **¿qué perfiles de pacientes conviene estudiar primero para ese programa, y cuál requiere revisión caso a caso?** Se usan GMM, KDE y DBSCAN como tres fuentes de evidencia; ningún centroide se interpreta como un “paciente tipo”, y la densidad de pacientes no se confunde con riesgo ni con demanda de recursos.

69 987

pacientes analizados
(99 340 ingresos, ninguno descartado por ser repetido)

3 segmentos

recurrentes o en transición:
36 % de los pacientes

18.8–25.4 %

readmisión en esos segmentos
frente a 10.4 % de promedio

0.88 vs 0.67

estabilidad de los grupos (ARI)
con historial vs. solo primer ingreso

2. Hallazgos principales

- **La recurrencia es lo que más diferencia a los pacientes.** Tres de cada cuatro tuvieron un solo ingreso en la base y forman una “cresta” muy densa; el resto forma un “abanico” disperso de pacientes que vuelven. Los tres métodos coinciden en esta división.
- **El riesgo se concentra en quienes vuelven:** los segmentos *Recurrentes* y *Muy recurrentes* (14 % de los pacientes) tienen ~25 % de readmisión en su primer ingreso, 2.4 veces el promedio; *En transición* (22 %) tiene 18.8 %.
- **Carga no es riesgo:** el segmento *Un solo ingreso, complejo* (25 %; 5 días, 18 medicamentos, 75 años) consume muchos recursos por ingreso pero se readmite menos que el promedio (5.5 %).
- **Usar todo el historial da grupos más confiables:** con el historial agregado K-means reproduce casi la misma partición al remuestrear (ARI 0.88) frente a 0.67 usando solo el primer ingreso de cada paciente.
- **Dos advertencias honestas:** la readmisión está en parte construida en los ejes (una readmisión es otro ingreso) y los pacientes más recientes tienen menos tiempo para volver (censura). Por eso las tasas se leen como descripción, no como prueba.

3. Datos y contrato experimental

Decisión	Acuerdo
Unidad de análisis	Un paciente = una fila que agrega todos sus ingresos válidos. No se duplica a nadie y no se pierde su evolución.
Limpieza (no recorte)	Se quitan 3 ingresos con género inválido y 2 423 con alta por fallecimiento u hospicio (sin seguimiento posible). No se recortan valores extremos: son pacientes reales.
Variables (10)	N.º de ingresos; promedios de estancia, análisis, procedimientos, medicamentos y diagnósticos; máximo de consultas, urgencias y hospitalizaciones previas; edad. $\log(1+x)$, estandarizadas y resumidas en 2 componentes principales (42 % de la varianza), ambas en desviaciones estándar (d.e.).
Ejes del plano	CP1 · carga clínica total (todo sube) y CP2 · recurrencia (más ingresos y visitas previas) frente a intensidad del ingreso (estancia, medicamentos).
Desarrollo / prueba	Pacientes ordenados por su primer ingreso: primer 70 % para elegir K, h y eps (muestra de 6 000); último 30 % (20 997) reservado y abierto una sola vez.

4. Evidencia de los tres métodos




Figura 1. Los tres métodos sobre los mismos ejes. **GMM**: 8 componentes gaussianas y sus contornos del 95 %; cuatro elipses alargadas cubren la cresta y cuatro el abanico. **KDE**: la mitad de los pacientes cae dentro del contorno negro, que ocupa solo el 4.3 % del área y está sobre la cresta. **DBSCAN**: una masa principal (94.7 %), un grupo pequeño de 15 pacientes muy recurrentes y 5.3 % de ruido.

Método	Qué estima	Parámetro elegido (con desarrollo)	Evidencia	Limitación
GMM	Densidad como mezcla de gaussianas y pertenencia de cada paciente	K = 8, covarianza completa (menor BIC entre 1 y 10)	Separa la cresta de un solo ingreso (56 %) de la transición (22 %) y los recurrentes (15 %)	Necesita 4 elipses para una sola cresta; poco estable al remuestrear (ARI 0.48)
KDE	Superficie de densidad (pacientes por unidad de área)	Ancho $h = 0.2$ d.e. (validación temporal en 3 bloques)	Núcleo muy concentrado en la cresta; el abanico es una meseta de baja densidad	No forma grupos; con $h = 0.1$ se fragmenta en 8 islas, con $h = 1.6$ es una loma
DBSCAN	Zonas densas conectadas y puntos aislados (ruido)	$\text{eps} = 0.3$ d.e., mínimo 15 vecinos (curva del 15.º vecino)	El ruido son pacientes muy recurrentes: 71 % volvió y 44 % tuvo alguna readmisión	Un solo eps no sirve para densidades tan distintas; con $\text{eps} = 0.15$ hay 10 grupos

Región que KDE suaviza y DBSCAN separa. El borde entre cresta y abanico ($\text{CP1} \approx -1$ a 1.5 ; $\text{CP2} \approx -1.5$ a 1) aparece en la KDE como una caída continua de densidad. DBSCAN con $\text{eps} = 0.15$ la *separa* (cresta en un grupo, abanico en otro) y con $\text{eps} = 0.3$ la *conecta*. Aquí la separación tiene sentido clínico (pacientes que no vuelven frente a los que sí), pero depende de eps : no es una frontera natural.

Punto ambiguo y punto raro no son lo mismo. El paciente más ambiguo (48 % de pertenencia a una componente y 21 % a otra) es un ingreso único muy intenso; el de menor densidad es un paciente con 23 ingresos al que el GMM asigna a una sola componente con total certeza. La pertenencia compara componentes entre sí; la densidad mide qué tan común es el paciente.

5. Sensibilidad: qué cambia y qué permanece

Se varía	Resultado	Conclusión
GMM: covarianza completa → diagonal	K por BIC pasa de 8 a 10 (borde de la rejilla)	El número de componentes no es un número de perfiles reales
KDE: $h = 0.1 \rightarrow 0.2 \rightarrow 1.6$ d.e.	Región del 50 %: 8 islas → 3 regiones → 1 loma	La cresta densa permanece en los anchos razonables
DBSCAN: $\text{eps} = 0.15 \rightarrow 0.3 \rightarrow 0.6$ ($m = 15$)	10 grupos (81 % cubierto) → 2 (95 %) → 1 (99 %)	La masa principal permanece; los grupos pequeños no
Unidad: primer ingreso → historial agregado	Estabilidad K-means 0.67 → 0.88; DBSCAN 0.78 → 0.79; GMM 0.73 → 0.48	El historial da particiones más reproducibles, salvo el GMM de 8 piezas

La *silhouette* se estima sobre una submuestra fija de 1 000 pacientes; con $\text{eps} = 0.3$ no está definida porque el grupo de 15 pacientes casi no aparece en esa submuestra. Por eso la configuración no se eligió por *silhouette*, sino por escala (92 % de los pacientes tiene 15 vecinos a menos de 0.3 d.e.) y por sensibilidad.

6. Segmentos de pacientes




Figura 2. Readmisión en menos de 30 días medida en el **primer** ingreso de cada paciente (la medida menos circular disponible) y tamaño de cada segmento. Se excluye una componente técnica de 17 pacientes (0.3 %) que el GMM usa para ajustar la punta de la cresta.

Segmento	Pacientes (desarr. / prueba)	Perfil (medianas)	Readmisión 1.er ingreso (desarr. / prueba)	Prioridad
Muy recurrentes	3.4 % / 2.1 %	5 ingresos; 3 hospitalizaciones, 1 urgencia y 1 consulta previas	25.4 % / 26.7 %	Revisión caso a caso
Recurrentes	11.1 % / 9.4 %	3 ingresos; 2 hospitalizaciones previas; 87 % volvió al menos una vez	25.3 % / 21.7 %	Alta: estudiar
En transición	21.9 % / 22.5 %	La mitad ya tuvo un segundo ingreso; 1 hospitalización previa	18.8 % / 13.5 %	Alta: estudiar
Frontera cresta–abanico	7.0 % / 6.2 %	Un ingreso típico; 24 % volvió	6.9 % / 3.7 %	Estándar
Un solo ingreso, complejo	25.2 % / 36.0 %	5 días, 18 medicamentos, 9 diagnósticos, 75 años	5.5 % / 2.6 %	Por carga, no por riesgo
Un solo ingreso, moderado	23.2 % / 18.4 %	3 días, 12 medicamentos, 5 diagnósticos	2.8 % / 1.9 %	Estándar
Un solo ingreso, breve	7.8 % / 5.0 %	2 días, 6 medicamentos, 4 diagnósticos, 55 años	0.9 % / 0.8 %	Estándar

Lectura del periodo reservado. El orden de riesgo entre segmentos se mantiene en los pacientes nuevos. Los tamaños cambian en la dirección que predice la censura: los pacientes recientes tuvieron menos tiempo para volver (1.29 ingresos de media frente a 1.48), así que crece el segmento de un solo ingreso complejo (25 % → 36 %) y la densidad estimada sube de bloque en bloque. No es una mejora del modelo.

7. Recomendación del comité

Observo que, con todo el historial, los pacientes se ordenan en una cresta densa de quienes tuvieron un solo ingreso (75 %) y un abanico de recurrentes, que los tres métodos reconocen. **Interpreto** que la recurrencia es el eje que más diferencia el riesgo, aunque su relación con la readmisión es en parte circular y el periodo reservado está censurado. **Recomendaría estudiar** (A) los *Recurrentes* (CP1 ≈ 0.5 a 2.9; CP2 ≈ 0 a 2.9; 11 %) y (B) los pacientes *En transición* (CP1 ≈ −1.3 a 2.0; CP2 ≈ −1.1 a 1.8; 22 %), donde un seguimiento puede actuar antes de que el paciente se vuelva recurrente. **Vigilaría** el extremo CP1 > 2.7, CP2 > 1.4 (*Muy recurrentes* y ruido de DBSCAN, ≈ 3–5 %) con revisión caso a caso. **No puedo concluir** que la recurrencia cause readmisiones, ni cuántos recursos se necesitan: faltan fechas, costos, capacidad y desenlaces fuera de la red.

8. Recomendaciones operativas

Acción	Para quién	Por qué
Programa de gestión de caso : llamada a las 48–72 h, cita de control en 7 días, conciliación de medicación, plan ante urgencias	Recurrentes y Muy recurrentes (14 %)	~25 % de readmisión en su primer ingreso, 2.4 veces el promedio; estable en el período reservado
Intervención preventiva al alta: educación sobre el tratamiento, cita temprana y seguimiento telefónico	En transición (22 %)	18.8 % de readmisión; es el punto donde todavía se puede evitar que el paciente se vuelva recurrente
Revisión clínica caso a caso antes del alta	Ruido de DBSCAN y extremo del abanico ($\approx 3\text{--}5\%$)	Combinaciones raras de muchos ingresos y urgencias; no encajan en un protocolo de grupo
Coordinación de alta y revisión farmacológica (no seguimiento intensivo)	Un solo ingreso, complejo (25 %)	Alta carga por ingreso (18 medicamentos, 75 años) pero riesgo de readmisión bajo
Calcular el segmento en cada alta con el historial disponible y monitorear mensualmente la tasa por segmento	Todos	El segmento cambia a medida que el paciente vuelve; la asignación debe actualizarse
Mejorar los datos : registrar fechas, readmisiones en otras redes, costos y capacidad del programa	Gerencia y TI	Sin esto no se puede estimar el retorno de la intervención ni corregir la censura

9. Limitaciones

- **Circularidad**: una readmisión registrada es otro ingreso, y el número de ingresos es un eje del plano. La readmisión en algún ingreso pasa de 4.3 % (1 ingreso) a 71 % (4 o más). Las tasas por segmento describen, no validan; se reporta la del primer ingreso por ser la menos circular.
- **Censura**: la base no tiene fechas; los pacientes que aparecen tarde tienen menos tiempo para acumular ingresos. Una evaluación justa exigiría contar solo los ingresos dentro de una ventana fija después del primero.
- **Readmisión incompleta**: solo se observan reingresos dentro de la red; el 4.3 % de pacientes con un solo ingreso figura como readmitido en otro lugar.
- **Grupos poco separados**: los pacientes forman un continuo; el GMM de 8 componentes es inestable (ARI 0.48) y sus componentes son aproximaciones de la densidad, no perfiles clínicos verdaderos. Los segmentos son convenciones útiles para priorizar.
- **Representación resumida**: el plano de dos componentes explica el 42 % de la variación de las 10 variables; diagnósticos, medicamentos específicos y destino al alta no entran en el plano.
- **Datos antiguos y sin contexto**: 1999–2008, 130 hospitales de EE. UU., sin factores sociales, adherencia ni identificación del hospital (no se puede evaluar la dependencia entre pacientes del mismo centro).
- **Densidad no es demanda**: la concentración de pacientes en una zona no indica cuántos recursos necesita; un paciente recurrente consume varios ingresos.

10. Reproducibilidad

Todo el análisis está en `semana08_pacientes_agregados.ipynb` (ejecutado de principio a fin, semilla 42). El notebook hermano `semana08_clustering_diabetes.ipynb` repite el laboratorio con solo el primer ingreso de cada paciente y sirve de comparación. Las figuras y cifras de este informe se regeneran con `python informe/figuras_semana8.py` y el PDF con `python informe/generar_informe.py`, desde la raíz del repositorio. Fuente del dataset: Strack et al. (2014), *BioMed Research International*; guía metodológica: *semana-08.html* y los cuadernos de la semana 8.